

Генерация реплик для технической поддержки

GPT-2 Fine-tuning на Ubuntu Dialogue Corpus

Проект: UbuntuSupportAI
Модель: GPT-2 (117M параметров)
Датасет: Ubuntu Dialogue Corpus — 26.8M строк, 3.5M пар после фильтрации
Период обучения: апрель 2026 | **GPU:** NVIDIA GeForce RTX 5070

1. Процесс обучения

Модель GPT-2 обучалась 3 эпохи на 500 000 отфильтрованных диалогов Ubuntu. Использовался AdamW оптимизатор с cosine learning rate decay и linear warmup (5%). Mixed precision FP16 для ускорения на GPU.

Параметры модели

Данные

Параметр	Значение
data_dir	./data/processed_filtered
max_train_samples	500 000
max_val_samples	10 000
max_test_samples	10 000
max_length	256 токенов

Модель

Параметр	Значение
model_name	gpt2
freeze_layers	0 (полный fine-tuning)
fp16	True (mixed precision)

Гиперпараметры обучения

Параметр	Значение
num_epochs	3
batch_size	32
gradient_accumulation_steps	2 (эффективный batch = 64)
learning_rate	3e-05
warmup_ratio	0.05 (5% шагов)
weight_decay	0.01
max_grad_norm	1.0
seed	42


Чекпоинты и мониторинг

Параметр	Значение
output_dir	./checkpoints

Параметр	Значение
save_every_n_steps	5 000
eval_every_n_steps	2 000
patience	5
log_examples_every	2 000
n_log_examples	5
log_grad_histogram_every	0 (отключено)
num_workers	0
resume_from	—


ClearML

Параметр	Значение
use_clearml	True
clearml_project	UbuntuSupportAI
clearml_task	GPT2_filtered




Модель содержит 124 443 648 параметров, все обучаемые. Embeddings расширены с 50 257 до 50 262 токенов для специальных токенов диалога.

Learning Rate Schedule



Linear warmup первые 5% шагов (1171 шаг), затем cosine decay до $1e-7$. Пик LR = $3e-5$, финальный LR $\approx 1e-7$.

Норма градиентов




Gradient norm до клиппинга. Высокие значения объясняются FP16 GradScaler — градиенты масштабируются перед `unscale_()`. Реальная норма после клиппинга ≤ 1.0 .

Train Loss и Perplexity




Train loss стабильно снижался с 3.19 до 1.86 за 3 эпохи. Perplexity: 24.3 → 6.42. Модель стала значительно увереннее в предсказаниях.

Validation Loss и Perplexity



Val loss снижался параллельно train loss — переобучения нет. Best val loss = 2.299, сохранён как checkpoint-best. Early stopping с patience=5 не сработал — модель улучшалась все 3 эпохи.

Test Loss и Perplexity



Финальные результаты на тестовой выборке:

- Test Loss = 1.845
- **Test Perplexity = 6.33** ✓

2. Бенчмарк — корпусные данные Ubuntu

Сравнение трёх моделей на 200 примерах из тестовой выборки Ubuntu Dialogue Corpus.

⚠ Примечание: этот бенчмарк частично нечестный — наш GPT-2 тестируется на данных из того же корпуса на котором обучался.

Итоговый Score (0-100): GPT-2 наш — 97.8 | Mistral 7B — 64.0 | GPT-2 Original — 28.5


Сравнение по данным датасета Ubuntu:

BLEU-1




- GPT-2 Original (P±PμP· PsP±CfC‡PμPSPëCłł) - Benchmark_GPT2_vs_Mistral7B
- GPT-2 PSP°C€ (C„PëP»CHC,CŁ. PrP°PSPSCłPμ) - Benchmark_GPT2_vs_Mistral7B
- Mistral 7B (Ollama) - Benchmark_GPT2_vs_Mistral7B

BLEU-2






- GPT-2 Original (P±PμP· PsP±CfC‡PμPSPëCłł) - Benchmark_GPT2_vs_Mistral7B
- GPT-2 PSP°C€ (C„PëP»CHC,CŁ. PrP°PSPSCłPμ) - Benchmark_GPT2_vs_Mistral7B
- Mistral 7B (Ollama) - Benchmark_GPT2_vs_Mistral7B

BLEU-4



- GPT-2 Original (P±PμP· PsP±CfC‡PμPSPëCłł) - Benchmark_GPT2_vs_Mistral7B
- GPT-2 PSP°C€ (C„PëP»CHC,CŁ. PrP°PSPSCłPμ) - Benchmark_GPT2_vs_Mistral7B
- Mistral 7B (Ollama) - Benchmark_GPT2_vs_Mistral7B





Интерпретация метрик: наши результаты относительно максимума

BLEU и ROUGE имеют теоретический максимум 100, но в диалоговых задачах он недостижим — на один вопрос существует множество правильных ответов, а метрика сравнивает только с одним референсом из датасета.

Ориентиры из научных работ по диалоговым системам

Метрика	Теор. макс	Типично для диалогов	Наш результат	Оценка
BLEU-1	100	15 – 30	8.6	ниже среднего
BLEU-4	100	1 – 5	1.43	в норме
ROUGE-L	100	15 – 35	11.84	ниже среднего
Perplexity	1	10 – 20	5.56	отлично

Почему BLEU/ROUGE ниже среднего

1. Датасет — IRC-чат 2004-2012. Ответы короткие, неформальные, часто не совпадают лексически с референсом даже если верные по смыслу.

2. **Одна референсная реплика** — метрики считаются относительно одного правильного ответа. На вопрос "how to install java?" есть 10+ верных ответов.
3. **Зашумлённость** — даже после фильтрации в данных есть устаревшие команды.

Perplexity = 5.56 — главный результат

Perplexity показывает насколько модель уверена в своих предсказаниях.

- GPT-2 без обучения на Ubuntu: PPL = **13.66** (неуверена)
- Наш GPT-2 после fine-tuning: PPL = **5.56** (уверена в 2.5 раза больше)
- Снижение PPL с 13.66 до 5.56 означает что модель хорошо освоила стиль и лексику технической поддержки Ubuntu.


Вывод: На корпусных данных наш GPT-2 (BLEU-4: 1.43, ROUGE-L: 11.84) превосходит Mistral 7B (BLEU-4: 1.18, ROUGE-L: 12.65) по большинству метрик. GPT-2 Original без обучения показывает минимальное качество.

3. Честный бенчмарк — реальные вопросы пользователей

60 вопросов составленных вручную — типичные вопросы по Ubuntu/Linux из 15 категорий (установка пакетов, сеть, SSH, GRUB и др.). Ни одна модель не видела эти вопросы раньше.

Итоговый Score: GPT-2 наш — 71.7 | Mistral 7B — 55.7 | GPT-2 Original — 18.4

Сравнение по новым сгенерированным данным:





По корпусному бенчмарку (Ubuntu Dialogue Corpus)

Perplexity = 5.56 — отлично. BLEU/ROUGE ниже среднего из-за зашумлённого датасета.

По честному бенчмарку (реальные вопросы пользователей)

BLEU/ROUGE ниже нормы у нашего GPT-2, Mistral 7B ближе к норме (ROUGE-L 20.32). Perplexity = 22.98 — выше нормы, модель менее уверена на незнакомых вопросах. Это объясняется тем что модель обучена на IRC-диалогах 2004-2012, а реальные вопросы написаны в другом стиле.

Вывод: На реальных вопросах Mistral 7B лучше по ROUGE-L (20.32 vs 12.12) — большая модель лучше генерализует на незнакомые вопросы. Наш GPT-2 в 4 раза быстрее (90 tok/s vs 22 tok/s) и в 60 раз меньше.

4. Итоги

Метрика	Значение
Test Perplexity	6.33

Метрика	Значение
ROUGE-L (корпус)	11.84
ROUGE-L (реальные)	12.12
Score корпусный	97.8 / 100
Скорость генерации	90 tok/s

Главный вывод: Fine-tuning GPT-2 (117M) на качественно отфильтрованных данных даёт конкурентоспособную специализированную модель. Ключевое ограничение — устаревший датасет (IRC 2004-2012). Для улучшения нужен Stack Overflow / Ask Ubuntu.